

Kronick (2020) e o dilema entre ajuste safe e controle contaminado em DiD

2026-03-23

1 Q&A

1. A aplicação da Kronick encaixa bem na extensão do paper?

Sim. O tratamento é não escalonado, o paper já compara uma especificação sem ajuste adicional com uma especificação que inclui um controle time-varying (`ln_pob`) e, crucialmente, também inclui um bloco de ajuste pré-tratamento `safe` baseado em população de `1990 × ano`.

2. Qual é o principal resultado substantivo?

O grande movimento vem de passar do modelo sem ajuste para o modelo `safe`. O coeficiente cai de 15.973 para 6.675, uma diferença de 9.298 mortes violentas por 100 mil. Depois disso, adicionar `ln_pob` quase não altera a estimativa: o deslocamento é de apenas 0.082.

3. O que isso sugere para a agenda do paper?

Sugere que uma ferramenta útil para o pesquisador aplicado é decompor separadamente o custo de omitir o bloco `safe` e o custo adicional de incluir um controle time-varying potencialmente contaminado. Neste caso, o primeiro é grande; o segundo é pequeno.

2 Desenho empírico

Kronick (2020) estima o efeito de um choque no mercado ilegal de drogas sobre mortes violentas em municípios venezuelanos. O tratamento municipal é fixo no tempo (`panam_sucre`) e o choque entra a partir de 1989, de modo que o regressor de interesse é:

$$Treat_{it} = Panam_i \times \mathbb{1}(t \geq 1989).$$

O ponto que interessa aqui é a comparação entre três famílias de especificação:

- **Sem ajuste adicional:** apenas tratamento, efeitos fixos de município e ano.
- **Ajuste safe:** efeitos fixos + interações entre ano e população municipal em 1990.
- **Controle contaminado:** ajuste `safe` + uma covariável time-varying realizada no pós-tratamento.

Na lógica da nota formal, o bloco `ano × população de 1990` é `safe` porque usa apenas informação pré-tratamento para permitir tendências diferenciadas por porte municipal. Já `ln_pob`, `pol_local` e `alc_oficialista` são covariáveis realizadas no painel e, portanto, candidatas a gerar viés por inclusão.

3 Dados e validações

```
sample_summary |>
  mutate(
    treat_share_obs = percent(treat_share_obs, accuracy = 0.1)
  ) |>
  kable()
```

```
caption = "Tabela 1. Resumo amostral do painel municipal de Kronick (2020)"
)
```

Tabela 1: Tabela 1. Resumo amostral do painel municipal de Kronick (2020)

n_obs	n_municipios	n_treated	n_control	year_min	year_max	treat_share_obs
7613	331	80	251	1958	2013	24.2%

```
validation_checks |>
  kable(
    caption = "Tabela 2. Checagens lógicas do painel e do tratamento"
  )
```

Tabela 2: Tabela 2. Checagens lógicas do painel e do tratamento

check	value	status
Duplicatas municipio-ano	0	OK
Mnimo de populao interpolada	425	OK
Valores ausentes nas variveis centrais	69	ALERTA
Tratamento coincide com panam_sucre x ps-1989	1	OK
Municipios com status panam_sucre varivel no tempo	0	OK

Há observações com valores ausentes nas variáveis centrais, concentradas nas extensões que usam `alc_oficialista`. O tratamento coincide exatamente com `panam_sucre` × pós-1989, não há duplicatas município-ano, e a população interpolada é sempre positiva.

4 Replicação das especificações principais

```
spec_table <- specs |>
  dplyr::select(
    spec_label, estimate, std_error, conf_low, conf_high,
    n_obs, published_benchmark, benchmark_gap, delta_vs_safe
  ) |>
  mutate(
    across(
      c(estimate, std_error, conf_low, conf_high, published_benchmark, benchmark_gap, delta_vs_safe),
      ~ ifelse(is.na(.x), NA, round(.x, 3))
    )
  )

kable(
  spec_table,
  col.names = c(
    "Especificação", "Estimativa", "Erro-padrão", "IC 95% inf.",
    "IC 95% sup.", "N", "Benchmark publicado", "Gap vs. benchmark",
    "Delta vs. safe"
  ),
```

```
caption = "Tabela 3. Efeito estimado do tratamento sobre mortes violentas por 100 mil habitantes"
)
```

Tabela 3: Tabela 3. Efeito estimado do tratamento sobre mortes violentas por 100 mil habitantes

Especifica	Estimativa	Erro-padr	IC 95% inf	IC 95% sup.	N	Benchmark publicado	Gap vs. benchmark	Delta vs. safe
Sem ajuste adicional	15.973	3.593	8.931	23.016	7613	16.0	-0.027	9.298
Bloco safe: ano x populao de 1990	6.675	2.875	1.041	12.310	7613	NA	NA	0.000
Safe + log da populao municipal	6.757	2.835	1.200	12.315	7613	6.8	-0.043	0.082
Safe + polcia municipal	6.398	2.820	0.872	11.925	7613	NA	NA	-0.277
Safe + prefeito governista	6.645	2.885	0.991	12.299	7544	NA	NA	-0.031
Safe + log da populao + polcia municipal	6.505	2.799	1.019	11.992	7613	NA	NA	-0.170
Safe + log da populao + polcia + prefeito	6.427	2.813	0.914	11.940	7544	NA	NA	-0.248

Os dois números mais importantes são:

- **Sem ajuste adicional:** 15.973.
- **Safe + ln_pob:** 6.757.

Eles reproduzem muito de perto a narrativa do artigo, que reporta algo em torno de 16 mortes por 100 mil na especificação simples e 6,8 na coluna com população realizada e tendências diferenciadas por tamanho municipal. O ganho analítico da nossa extensão é inserir explicitamente o modelo **safe** intermediário, que não aparece como coluna central no artigo, mas é o que explica quase todo o deslocamento.

```
plot_df <- specs |>
  mutate(
    spec_label = factor(spec_label, levels = rev(spec_label))
  )

ggplot(plot_df, aes(x = estimate, y = spec_label)) +
  geom_vline(xintercept = 0, linewidth = 0.4, linetype = "dashed", color = "gray50") +
  geom_errorbarh(aes(xmin = conf_low, xmax = conf_high), height = 0.15, color = "#2f5c8a") +
  geom_point(size = 2.5, color = "#b2472f") +
  labs(
    x = "Efeito do tratamento sobre mortes violentas por 100 mil",
    y = NULL
  ) +
  theme_minimal(base_size = 11)
```

A figura deixa claro que o salto substantivo é entre **Sem ajuste adicional** e **Bloco safe**. Depois disso, as extensões com controles time-varying deslocam pouco a estimativa.

5 Decomposição IVB em torno do modelo safe

Definimos:

$$OVB_{safe} = \hat{\tau}^{omit} - \hat{\tau}^{safe}$$




Figura 1: Figura 1. Coeficiente do tratamento em cada especificao com intervalo de confiana de 95%.

e, para cada controle pós-tratamento candidato Z_{it} ,

$$IVB_{post}(Z) = \hat{\tau}^{long}(Z) - \hat{\tau}^{safe} = -\hat{\theta}_Z \hat{\pi}_Z.$$

Aqui, $\hat{\theta}_Z$ é o coeficiente de Z_{it} no modelo longo, e $\hat{\pi}_Z$ é o coeficiente do tratamento na regresso auxiliar de Z_{it} sobre o tratamento e o bloco safe.

```
ivb_table <- ivb_diag |>
  dplyr::select(
    control_label, beta_safe, beta_long, theta, pi,
    ivb_formula, ivb_direct, check, ovb_safe, aux_n_obs
  ) |>
  mutate(
    across(
      c(beta_safe, beta_long, theta, pi, ivb_formula, ivb_direct, check, ovb_safe),
      ~ round(.x, 3)
    )
  )

kable(
  ivb_table,
  col.names = c(
    "Controle", "Beta safe", "Beta longo", "Theta",
    "Pi", "IVB = -theta*pi", "IVB direto", "Check",
    "OVb_safe", "N"
  ),
)
```

```
caption = "Tabela 4. Decomposição do deslocamento ao incluir cada controle time-varying"
)
```

Tabela 4: Tabela 4. Decomposição do deslocamento ao incluir cada controle time-varying

Controle	Beta safe	Beta longo	Theta	Pi	IVB = -theta*pi	IVB direto	Check	OVB_safeN	
Log da populao municipal	6.675	6.757	8.112	-	0.082	0.082	0	9.298	7613
				0.010					
Presena de polcia municipal	6.675	6.398	7.748	0.036	-0.277	-0.277	0	9.298	7613
Prefeito governista	6.609	6.645	-	0.041	0.036	0.036	0	9.364	7544
			0.871						

Os resultados são nítidos:

- Para `ln_pob`, o deslocamento em relação ao modelo `safe` é de apenas 0.082.
- Para `pol_local`, o deslocamento é maior em valor absoluto, -0.277, mas ainda muito menor que `OVB_safe`.
- Para `alc_oficialista`, o deslocamento é de 0.036 numa amostra menor por conta de dados ausentes.

Em todos os casos, a identidade `IVB = -theta*pi` fecha numericamente. Isso é exatamente a extensão aplicada que a agenda do paper pede: quantificar o custo de incluir um controle potencialmente contaminado **condicionalmente** a um bloco `safe` bem escolhido.

6 Implicações para a simulação

Esta aplicação sugere um tom específico para a próxima rodada de simulação:

1. O cenário base deve permitir um grande `OVB_safe`, porque a heterogeneidade de tendência por porte municipal claramente importa.
2. O cenário base não precisa impor um grande `IVB_post` para `ln_pob`; pelo contrário, um caso em que ele é pequeno é empiricamente plausível.
3. Vale incluir extensões em que um controle time-varying adicional, como `pol_local`, gere deslocamentos moderados, mas ainda inferiores ao custo de omitir o bloco `safe`.

Em termos práticos, Kronick (2020) parece menos um caso em que “controlar a variável realizada destrói a identificação” e mais um caso em que “não separar ajuste `safe` de ajuste contaminado leva o pesquisador a fazer a pergunta errada”.

7 Reprodutibilidade

O relatório executa o script `kronick_replication_ivb.R`, que por sua vez:

- extrai os dados brutos a partir de `replicationdata_dk_tojcr_v2.zip`, se necessário;
- valida o painel;
- estima todas as especificações;
- salva os resultados em CSV.

Os arquivos intermediários produzidos pelo script são:

- `kronick_sample_summary.csv`
- `kronick_validation_checks.csv`
- `kronick_specification_estimates.csv`
- `kronick_ivb_diagnostics.csv`

sessionInfo()

```
## R version 4.4.2 (2024-10-31)
## Platform: aarch64-apple-darwin20
## Running under: macOS Sonoma 14.7.3
##
## Matrix products: default
## BLAS:   /Library/Frameworks/R.framework/Versions/4.4-arm64/Resources/lib/libRblas.0.dylib
## LAPACK: /Library/Frameworks/R.framework/Versions/4.4-arm64/Resources/lib/libRlapack.dylib; LAPACK v
##
## locale:
## [1] C
##
## time zone: America/Sao_Paulo
## tzcode source: internal
##
## attached base packages:
## [1] stats      graphics  grDevices  utils      datasets  methods    base
##
## other attached packages:
## [1] tidyr_1.3.1   haven_2.5.4   fixest_0.12.1 scales_1.4.0  readr_2.1.5
## [6] knitr_1.51    ggplot2_4.0.2 dplyr_1.2.0
##
## loaded via a namespace (and not attached):
## [1] sandwich_3.1-1      generics_0.1.4      dreamerr_1.5.0
## [4] lattice_0.22-6      hms_1.1.3           digest_0.6.37
## [7] magrittr_2.0.4      evaluate_1.0.3      grid_4.4.2
## [10] estimability_1.5.1  RColorBrewer_1.1-3  mvtnorm_1.3-3
## [13] fastmap_1.2.0       Matrix_1.7-1        Formula_1.2-5
## [16] survival_3.7-0      multcomp_1.4-28     purrr_1.2.1
## [19] TH.data_1.1-3       stringmagic_1.2.0   codetools_0.2-20
## [22] numDeriv_2016.8-1.1 cli_3.6.5           crayon_1.5.3
## [25] rlang_1.1.7         bit64_4.5.2         splines_4.4.2
## [28] withr_3.0.2         yaml_2.3.10         parallel_4.4.2
## [31] tools_4.4.2         tzdb_0.5.0          coda_0.19-4.1
## [34] forcats_1.0.0       vctrs_0.7.1         R6_2.6.1
## [37] zoo_1.8-12          lifecycle_1.0.5     emmeans_1.11.2-8
## [40] bit_4.5.0           vroom_1.6.5         MASS_7.3-61
## [43] pkgconfig_2.0.3     pillar_1.11.1       gtable_0.3.6
## [46] glue_1.8.0          Rcpp_1.1.1          xfun_0.56
## [49] tibble_3.3.1        tidyselect_1.2.1    farver_2.1.2
## [52] xtable_1.8-4        htmltools_0.5.8.1   nlme_3.1-166
## [55] labeling_0.4.3      rmarkdown_2.29      compiler_4.4.2
## [58] S7_0.2.0
```